




$$V = s^3$$

PREDICCIÓN DE COSTO DE VIVIENDAS

MÉTODOS NUMÉRICOS

INTEGRANTES:

ALDAZ CAMILY

RIOS JARVIN

VISCAINO STIVEN

Descripción del proyecto


EL PROYECTO ESTA BASADO EN PREDECIR EL PRECIO DE UNA VIVIENDA TOMANDO EN CUENTA SUS CARACTERISTICAS FÍSICA Y ESTRUCTURALES PARA ESTO SE USO UN MODELO HEDÓNICO, EL CUAL PERMITE SUMAR COMO CADA ATRIBUTO O DESCRIPCION DE LA VIVIENDA COMO EL NÚMERO DE GARAJES,ÁREA DE LA CASA,ANTIGUEDAD ETC; INFLUYEN EN EL PRECIO FINAL DE LA MISMA.

NOS BASAREMOS EN EL METODO DE MINIMOS CUADRADOS PARA RELACIONAR EL PRECIO Y SUS CARACTERÍSTICAS CON EL FIN DE OBTENER UN MODELO NÚMÉRICO QUE PERMITA PREDECIR EL PRECIO DE NUEVAS VIVIENDAS DE FORMA FUNDAMENTADA

OBJETIVO

ANALIZAR LOS PRECIOS DE LAS VIVIENDAS EN LA CIUDAD DE AMES, IOWA, EVALUANDO LAS VARIABLES QUE TIENEN MAYOR IMPACTO EN SU VALOR. PARA ESTO, SE DISEÑARÁ UN MODELO MATEMÁTICO LINEAL AJUSTADO MEDIANTE EL MÉTODO DE MÍNIMOS CUADRADOS, CON EL PROPÓSITO DE APROXIMAR EL PRECIO DE LAS VIVIENDAS Y COMPRENDER MEJOR EL COMPORTAMIENTO DEL MERCADO INMOBILIARIO DE ESTA ZONA.


DESCRIPCIÓN DEL DATASET



Tamaño de la casa



Ubicación



Número de habitaciones



DONDE, ENTRE LAS 80 VARIABLES, SE CLASIFICAN EN:

- VARIABLES DE SUPERFICIE: ESTAS VARIABLES PERMITEN CUANTIFICAR EL ESPACIO UTIL DE LA VIVIENDA, UN FACTOR ESENCIAL EN LA DETERMINACION DEL PRECIO
- VARIABLES DE CALIDAD Y CONDICIÓN: ESTAS VARIABLES REFLEJAN EL ESTADO FÍSICO Y CONSTRUCTIVO DE LA CASA, ELEMENTOS DIRECTAMENTE ASOCIADOS A SU VALOR EN EL MERCADO
- VARIABLES DE GARAJE: SU UTILIDAD RADICA EN QUE LA PRESENCIA Y TAMAÑO DEL GARAJE INFLUYEN SIGNIFICATIVAMENTE EN EL PRECIO DE VENTA
- VARIABLES DE BAÑOS Y CUARTOS: ESTAS VARIABLES CAPTURAN EL NIVEL DE FUNCIONALIDAD Y COMODIDAD DE LA VIVIENDA
- VARIABLES TEMPORALES: PERMITEN CONSIDERAR LA ANTIGÜEDAD Y LAS REMODELACIONES, FACTORES QUE AFECTAN LA DEPRECIACIÓN Y VALORIZACION
- VARIABLES DE TERRENO: ESTAS CARACTERSTICAS DESCRIBEN EL TAMAÑO Y FORMA DEL TERRENO, LO CUAL INFLUYE DIRECTAMENTE EN EL COSTO DEL SUELO
- VARIABLES DEL VECINDARIO: DESCRIBEN LA ZONA DONDE ESTAA UBICADA LA VIVIENDA, PERMITIENDO CAPTURAR DIFERENCIAS DE VALOR ENTRE SECTORES

VARIABLES
DEL DATASET

VARIABLES DEL DATASET

	A	B	C	D	E	F	G	H	I	J	K	L
	Id	LotArea	OverallQual	YearBuilt	BsmtFinSF1	TotalBsmtSF	1stFlrSF	GrLivArea	FullBath	GarageCars	GarageArea	SalePrice
	1	8450	7	2003	706	856	856	1710	2	2	548	208500
	2	9600	6	1976	978	1262	1262	1262	2	2	460	181500
	3	11250	7	2001	486	920	920	1786	2	2	608	223500
	4	9550	7	1915	216	756	961	1717	1	3	642	140000
	5	14260	8	2000	655	1145	1145	2198	2	3	836	250000
	6	14115	5	1993	732	796	796	1362	1	2	480	143000

Variable	Descripción
GrLivArea	Área habitable principal
OverallQual	Calidad construcción general
GarageCars	Capacidad vehículos garaje
GarageArea	Tamaño físico garaje
TotalBsmtSF	Área total sótano
1stFlrSF	Superficie primer piso
BsmtFinSF1	Sótano terminado habitable
FullBath	Número baños completos
LotArea	Tamaño total terreno
YearBuilt	Antigüedad construcción vivienda

FASES PROPUESTAS

Desde la planificacion inicial del proyecto presentados en el primer bimestre se propusieron las siguientes etapas de trabajo:

1. Se planteo una preparacion inicial del dataset utilizando el archivo train.csv con el objetivo de alcanzar una matriz de datos coherente con l modelo matematico planteado en esta etapa se edectuo la separacion de la variable objetico (salePrice)

2. El modelo lineal multivariable puede escribirse en forma matricial:

$$(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)$$

Se construyo la matriz X con las 10 variables explicativas ademas se añadio una columna de unos para representar el termino independiente

1. Se organizo las variables en forma matricial para aplicar el modelo lineal multivariable y definir el sistema de ecuaciones correspondiente al metodo de mínimos cuadrados

ETAPA DEL ANÁLISIS

-Selección y revisión de datos


Se trabajó únicamente con variables seleccionadas del archivo train.csv usando las variables más importantes mismas que son fundamentadas para usarlas en el modelo lineal multivariable

-Análisis descriptivo

Se analizaron parámetros estadísticos necesarios para el procesamiento adecuado del modelo se usaron medias y desviación estándar utilizando más adelante en el proceso de normalización además la variabilidad significa en algunas variables relacionada con características estructurales

-Preparación para el modelo

Las variables fueron organizadas de manera matricial para la implementación del modelo lineal multivariable determinando así el sistema de ecuaciones correspondiente al método de mínimos cuadrados además en etapas posteriores se aplicaron técnicas de normalización y análisis mediante diagramas de caja para evaluar el impacto de valores atípicos en el ajuste del modelo



MÉTODOS NUMÉRICOS UTILIZADOS

MINIMOS CUADRADOS

El modelo hedónico clásico adopta la forma lineal siguiente

$$P = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_k X_k + \varepsilon$$

donde:

- P : precio de venta de la vivienda (variable SalePrice).
- $X_1, X_2, \dots, X_k$: características de la vivienda (superficie, calidad, antigüedad, número de baños, garaje, barrio, etc.).
- $\beta_1, \beta_2, \dots, \beta_k$: precios implícitos o marginales de cada característica (cuántos dólares aporta cada unidad adicional de la característica).
- α : constante o término independiente.
- ε : término de error aleatorio.

Los parámetros β (y α) se estiman mediante el método de mínimos cuadrados, que consiste en minimizar la suma de los cuadrados de los errores.

$$E = \sum_{i=1}^n [y_i - (a_1 x_i + a_0)]^2 \quad \Rightarrow \quad \min \sum_{i=1}^n [y_i - f(x_i)]^2$$

*FUNCIONES
IMPLEMENTADAS*


1. Carga y preparación de datos

Funciones:

- `def cargar_dataset(ruta_archivo):` carga el dataset desde un archivo CSV.
- `def cargar_datos(ruta_archivo):` carga el dataset para otros modelos.
- `def separar_variables(df, columna_objetivo):` separa variables independientes X y dependiente y.
- `def preparar_datos(X, y, columna_id):` elimina columnas no importantes y convierte los datos a forma matricial.
- `def separar_y_normalizar(df, columna_objetivo="SalePrice", columna_id="Id"):` separa y normaliza los datos.

Estructuras de datos utilizadas:

- DataFrame: organiza datos en filas y columnas
- Matrices NumPy: arreglos bidimensionales para realizar operaciones
- Vectores NumPy: arreglos unidimensionales para el calculo de datos numéricos.



2. Construcción del modelo matricial

Funciones:

def construir_matriz_modelo(X_norm): construye la matriz del modelo a partir de datos normalizados.

Estructuras de datos utilizadas:

Matrices NumPy: arreglos bidimensionales para realizar operaciones

3. Método de mínimos cuadrados

Funciones:

def calcular_minimos_cuadrados(matriz_A, vector_b): calcula los coeficientes del modelo mediante ecuaciones .

Estructuras de datos utilizadas:

- Matriz NumPy
- Vector NumPy

4. Predicción

Funciones:

- `def predecir_precios(matriz_A, coeficientes)`: calcula los valores estimados del modelo base.
- `def predecir (A, coeficientes)`: realiza predicciones con datos normalizados.
- `def predecir_test_modelo_3(X_test_norm_m3, y_test_m3, coeficientes_train_m3)`: predice sobre el conjunto de prueba del modelo 3.

Estructuras de datos utilizadas:

- Matrices NumPy
- Vectores NumPy

5. Evaluación del modelo

Funciones:

- `def calcular_rmse(y, precios_estimados)`: calcula el RMSE del modelo base.
- `def calcular_rmse_normalizado(y, y_pred_norm)`: calcula el RMSE del modelo normalizado.
- `def generar_tabla_errores(df, y, precios_estimados)`: genera una tabla con errores absolutos.
- `def obtener_top_mejores_predicciones(df, y, precios_estimados, top_n=10)`: obtiene las mejores predicciones.
- `def obtener_top_peores_predicciones(df, y, precios_estimados, top_n=10)`: obtiene las peores predicciones.
- `def evaluar_vivienda_por_id(df, y, precios_estimados)`: evalúa una vivienda específica.

Estructuras de datos utilizadas:

- DataFrame
- Vectores NumPy



6. Visualización de resultados

Funciones:

- `def graficar_predicciones(y_real, y_estimado)`: grafica valores reales vs estimados.
- `def graficar_comparacion_por_id(id_vivienda, precio_real, precio_estimado)`: compara precios por vivienda.
- `def analizar_influencia_variables(X, coeficientes_modelo, columna_id="Id")`: analiza influencia de variables.
- `def graficar_influencia_variables(tabla_influencia)`: grafica la influencia de las variables.
- `def graficar_top_mejores_predicciones(top_mejores)`: grafica mejores predicciones.
- `def graficar_top_peores_predicciones(top_peores)`: grafica peores predicciones.
- `def graficar_rmse(RMSE)`: grafica el RMSE.
- `def graficar_error_absoluto_por_vivienda(tabla_errores)`: grafica el error absoluto.

Estructuras de datos utilizadas:

- DataFrame
- Vectores NumPy
- Valores escalares: representan un único dato numérico sin dimensiones



7. Modelo 3 (outliers y train-test)


Funciones:

- `def limpiar_outliers_boxplot(df, columna_objetivo="SalePrice")`: elimina valores atípicos.
- `def dividir_train_test_modelo_3(df_m3, test_size=0.3, random_seed=42)`: divide datos en entrenamiento y prueba.
- `def entrenar_modelo_3(df_m3, columna_objetivo="SalePrice", columna_id="Id")`: entrena el modelo 3.
- `def entrenar_modelo_3_con_train(X_train_norm_m3, y_train_m3)`: entrena usando solo el conjunto de entrenamiento.

Estructuras de datos utilizadas:


- DataFrame
- Matrices NumPy
- Vectores NumPy

FLUJOGRAMA DE
INTERACCIÓN ENTRE
FUNCIONES
IMPLEMENTADAS.



MODELO SIN
NORMALIZAR

VISUALIZACIÓN DEL AJUSTE DEL MODELO



Grafica la comparación entre los valores reales y los valores estimados del modelo de mínimos cuadrados.

Parámetros:

y_real (array-like): Valores reales del precio.

y_estimado (array-like): Valores estimados por el modelo.

EVALUAR_VIVIENDA_ POR_ID


Evalúa una vivienda específica a partir de su ID, mostrando el precio real, el precio estimado, los errores y la gráfica comparativa.

Parámetros:


df (DataFrame): Dataset completo.

y (Series): Variable objetivo (precio real).

precios_estimados (ndarray): Precios estimados por el modelo.




INFLUENCIA_VARIABLES





TOP_PECORES_PREDICCIONES

- 1) Gráfico de barras comparando precio real vs estimado.
- 2) Gráfico de dispersión precio real vs estimado




TOP_MEJORES_PREDICCIONES

- 1) Gráfico de barras comparando precio real vs estimado.
- 2) Gráfico de dispersión precio real vs estimado



RMSE



Valor del RMSE del modelo de mínimos cuadrados sin normalización.


Parámetros:

RMSE (float): Valor del error cuadrático medio.


ERROR_ABSOLUTO_POR_VIVIENDA

Error absoluto por vivienda para el modelo de mínimos cuadrados sin normalizar.

Parámetros: `tabla_errores` (DataFrame): Tabla de errores por vivienda.




MODELO NORMALIZADO



Prediccion_general_normalizada


Comparación entre precios reales y precios estimados del modelo normalizado por mínimos cuadrados.

PREDICCION_INDIVIDUAL




Precio Real vs Precio
Estimado para una
vivienda individual

INFLUENCIA DE LAS VARIABLES EN EL MODELO NORMALIZADO.




TOP_PECORES_PREDICCIONES_NORMALIZADO

- 1) Gráfico de barras comparando precio real vs estimado.
- 2) Gráfico de dispersión precio real vs estimado




TOP_MEJORES_PREDICCIONES_NORMALIZADO


- 1) Gráfico de barras: Precio real vs Precio estimado.
- 2) Gráfico de dispersión: Precio real vs Precio estimado



RMSE_NORMALIZADO




ERROR_ABSOLUTO_POR_VIVIENDA_NORMALIZADO



MODELO 3 - NORMALIZADO CON DIAGRAMA DE CAJAS


Predicción general modelo 3= Normalizado con diagrama de cajas

**Comparación entre
precios reales y precios
estimados del Modelo 3
(Boxplot + Normalización)**




PREDICCIÓN INDIVIDUAL MODELO 3- NORMALIZADO CON DIAGRAMA DE CAJAS

COMPARACIÓN ENTRE EL
PRECIO REAL Y EL
PRECIO ESTIMADO
PARA UNA VIVIENDA
ESPECÍFICA USANDO EL
MODELO 3




Influencia_variables_modelo_3-Normalizado con diagrama de cajas



TOP PEORES PREDICCIONES MODELO 3-NORMALIZADO CON DIAGRAMA DE CAJAS


- 1) Gráfico de barras: Precio real vs Precio estimado.
- 2) Gráfico de dispersión: Precio real vs Precio estimado




TOP MEJORES PREDICCIONES MODELO 3-NORMALIZADO CON DIAGRAMA DE CAJAS

1) Gráfico de barras: Precio real vs Precio estimado.


2) Gráfico de dispersión: Precio real vs Precio estimado



RMSE DEL MODELO 3 (BOXPLOT + NORMALIZADO).




Grafica el error absoluto por vivienda para el MODELO 3 (Boxplot + Normalizado).




TRAIN/TEST

Comparación entre precios reales y precios estimados sobre el conjunto TEST del MODELO 3 (70/30).




RMSE del MODELO 3 evaluado sobre el conjunto TEST (70/30).




TOP 10 de peores predicciones del MODELO 3 evaluado sobre el conjunto TEST:

- 1) Barras: Precio real vs Precio estimado
- 2) Dispersión: Error absoluto

Top 10 Peores — Precio Real vs Estimado (TEST)



Top 10 Peores — Error Absoluto (TEST)




TCP 10 de mejores predicciones del MODELO 3 evaluado sobre el conjunto TEST:


1) Barras: Precio real vs Precio estimado

2) Dispersión: Error absoluto


Top 10 Mejores — Precio Real vs Estimado (TEST)



Top 10 Mejores — Error Absoluto (TEST)




Grafica el error absoluto por vivienda para el MODELO 3 TEST (Boxplot + Normalizado).




COMPARATIVAS

COMPARACIONES DE LOS MODELOS

Sin normalizar



Normalizado




COMPARACIONES DE LOS MODELOS


Modelo 3 - Normalizado con diagrama de cajas

Train/test

Modelo 3 (Boxplot + Normalizado) — Predicción General



Modelo 3 — Predicción sobre datos TEST (70/30)




COMPARACIONES DE LOS MODELOS


Sin normalizar

Normalizado


Influencia de las variables en el modelo de predicción




Influencia de las variables en el modelo normalizado



Comparación Final de RMSE — Todos los Modelos



Error Absoluto por Vivienda — Modelo 3 TEST (Boxplot + Normalizado)



Error Absoluto por Vivienda — Modelo Sin Normalizar

