
Predicción de costo de viviendas

[Proyecto Segundo Bimestre]

ASIGNATURA: Métodos Numéricos
INTEGRANTES: Aldaz Camily, Rios Jarvin, Viscaino Stiven

FECHA DE ENTREGA: 04/02/2026

Contenido

DESCRIPCIÓN DEL PROYECTO	1
PROBLEMA DEL MUNDO REAL	1
OBJETIVOS	1
MARCO TEÓRICO	1
DESCRIPCIÓN DEL DATASET	3
VARIABLES DEL DATASET	4
RESOLUCIÓN	5
FLUJOGRAMA DE INTERACCIONES ENTRE FUNCIONES IMPLEMEN- TADAS	9
LINK DEL REPOSITORIO	11
ESTADÍSTICAS DE CONTRIBUCIÓN DEL REPOSITORIO	12
CONCLUSIONES	12
RECOMENDACIONES	13
REFERENCIAS	13

DESCRIPCIÓN DEL PROYECTO

El proyecto esta basado en predecir el precio de una vivienda tomando en cuenta sus características física y estructurales para esto se uso un modelo hedónico, el cual permite sumar como cada atributo o descripción de la vivienda como el número de garajes, área de la casa, antigüedad etc; influyen en el precio final de la misma.

Nos basaremos en el metodo de minimos cuadrados para relacionar el precio y sus características con el fin de obtener un modelo numérico que permita predecir el precio de nuevas viviendas de forma fundamentada

PROBLEMA DEL MUNDO REAL

En la vida real, calcular el precio de una vivienda siempre ha sido un proceso complicado, porque cada casa es diferente y factores como el area habitable, la calidad, los baños ,l garaje y sótanos, influyen de maneras distintas. Tanto compradores como vendedores necesitan una referencia confiable para saber si un precio es razonable y está acorde a las características de la vivienda

Este proyecto busca trabajar justamente esa necesidad: aproximar el precio de una vivienda usando sus características más importantes, basandonos en datos reales de viviendas de Ames, Iowa, de esta forma, se recrea un escenario similar al que enfrentan personas y agencias al momento de evaluar klas diferentes propiedades

OBJETIVO

- Analizar los precios de las viviendas en la ciudad de Ames, Iowa, evaluando las variables que tienen mayor impacto en su valor. Para sto, se diseñara un modelo matemático lineal ajustado mediante el Metodo de Minimos Cuadrados, con el proposito de aproximar el precio de las viviendas y comprender mejor el comportamiento del mercado inmobiliario de esta zona.

MARCO TEÓRICO

La decisión del precio de las viviendas es un tema clave en la economía y en el estudio del mercado inmobiliario, el costo de una vivienda no es aleatorio es un reflejo del valor de cada cosa que compone a la vivienda ya sean estructurales, calidad o ubicación.

Este modelo de dar un valor por separado a cada cosa que compone a la vivienda, se llama modelo de precios hedónicos y fue propuesta por Rosen (1974), segun Rosen el precio que se observa de un bien como la vivienda, revela un conjunto de precios implícitos debido a las características que presente el mismo, es decir, al adquirir la vivienda el comprador no esta pagando unicamente por la estrucutra física sino por un conjuntode atributos como el tamaño, el número de habitaciones, la calidad de los acabdos, la localización etc; cada

uno de los elementos contribuye al precio final, de acuerdo con el valor que el mercado otorga.

En la práctica, los modelos hedónicos se calculan a través de la regresión lineal utilizando el método mínimos cuadrados, este permite hallar los coeficientes que optimiza la suma de errores entre los reales y los estimados. “Clásicamente, los modelos de regresión hedónica del precio de la vivienda persiguen determinar las características constructivas y localizativas que más influyen sobre el precio de la vivienda, cuantificar el precio implícito de las mismas y estimar el precio de este bien urbano” [1]

El modelo hedónico clásico adopta la forma lineal siguiente (Chica Olmo et al., 2007; Bilbao Terol, 2000):

$$P = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \cdots + \beta_k X_k + \varepsilon \quad (1)$$

donde:

- P : precio de venta de la vivienda (variable **SalePrice**).
- $X_1, X_2, \dots, X_k$: características de la vivienda (superficie, calidad, antigüedad, número de baños, garaje, barrio, etc.).
- $\beta_1, \beta_2, \dots, \beta_k$: **precios implícitos o marginales** de cada característica (cuántos dólares aporta cada unidad adicional de la característica).
- α : constante o término independiente.
- ε : término de error aleatorio.

Los parámetros β (y α) se estiman mediante el método de mínimos cuadrados, que consiste en minimizar la suma de los cuadrados de los errores:

$$\min \sum_{i=1}^n \varepsilon_i^2 = \min \sum_{i=1}^n (P_i - \hat{P}_i)^2 \quad (2)$$

donde $\hat{P}_i = \alpha + \beta_1 X_{i1} + \cdots + \beta_k X_{ik}$ es el precio predicho por el modelo para la observación i .

Este procedimiento es **idéntico** al estudiado en la asignatura de Métodos Numéricos para el ajuste lineal por mínimos cuadrados, pero extendido al caso multivariante (varias variables explicativas simultáneamente). La solución analítica se obtiene derivando la función de error respecto a los parámetros e igualando a cero tal como se aprendió en clase:

$$E = \sum_{i=1}^n [y_i - (a_1 x_i + a_0)]^2 \quad \Rightarrow \quad \min \sum_{i=1}^n [y_i - f(x_i)]^2 \quad (3)$$

Bilbao Terol (2000) aplica este método en el mercado asturiano y concluye que las características estructurales y de calidad representan el 70 % en la variación del precio final, destacando la relevancia en factores como la superficie útil, el estado de conservación y la ubicación.

El método de mínimos cuadrados es útil para este análisis, permite determinar de forma eficiente y directa la combinación lineal de variables que mejor se ajusta a los datos observados sin requerir iteraciones o búsqueda de raíces, se utiliza de manera extensa en texto académicos internacionales y nacionales sobre la evaluación inmobiliaria [2, 3]

Por lo tanto, en este proyecto se utilizará un modelo hedónico calculado mediante el método de mínimos cuadrados sobre el conjunto de datos “House Prices - Advanced Regression Techniques” de Kaggle, con el propósito de medir el impacto de cada característica de la vivienda en su precio de venta y desarrollar una herramienta predictiva que sea precisa y fácil de interpretar.

DESCRIPCIÓN DEL DATASET

El proyecto utiliza el dataset “House Prices: Advanced Regression Techniques”, el mismo fue escogido durante la selección del tema del dominio, el dataset proviene de la ciudad de Ames, Iowa (Estados Unidos), el cual fue escogido porque se usa mucho en investigaciones e incluso en competencias de predicción inmobiliaria.

Nuestro dataset posee 2919 viviendas, divididas en 1460 registros en el conjunto de entrenamiento (train.csv) y 1459 en el conjunto de prueba (test.csv), con 81 variables que describen las características físicas, estructurales y funcionales de las viviendas.

En este trabajo utilizaremos el conjunto de entrenamiento, ya que incluye la variable objetivo (SalePrice), necesaria para ajustar el modelo mediante el método de mínimos cuadrados

El objetivo final del dataset es servir como base para la predicción del precio de venta de una vivienda.

Donde, entre las 80 variables, se clasifican en:

- **Variables de superficie:** Estas variables permiten cuantificar el espacio útil de la vivienda, un factor esencial en la determinación del precio
- **Variables de calidad y condición:** Estas variables reflejan el estado físico y constructivo de la casa, elementos directamente asociados a su valor en el mercado
- **Variables de garaje:** Su utilidad radica en que la presencia y tamaño del garaje influyen significativamente en el precio de venta
- **Variables de baños y cuartos:** Estas variables capturan el nivel de funcionalidad y comodidad de la vivienda
- **Variables temporales:** Permiten considerar la antigüedad y las remodelaciones, factores que afectan la depreciación y valorización
- **Variables de terreno:** Estas características describen el tamaño y forma del terreno, lo cual influye directamente en el costo del suelo
- **Variables del vecindario:** Describen la zona donde está ubicada la vivienda, permitiendo capturar diferencias de valor entre sectores

VARIABLES DEL DATASET QUE SE VAN A UTILIZAR

Para este proyecto se eligieron 10 variables numéricas que influyen de manera clara en el precio de una vivienda. Estas características ya han sido mencionadas en estudios y análisis inmobiliarios, y además, al ser valores cuantitativos, resultan más manejables de trabajar dentro del modelo que se va a construir.

Estas variables se relacionan con el problema porque permiten representar numéricamente los factores que en el mundo real determinan el precio de vivienda de esta manera el modelo matemático logra aproximar el comportamiento del mercado inmobiliario de Ames- Iowa.

1. **GrLivArea (Área habitable sobre el nivel del suelo)**

Es la variable más correlacionada con el precio. En estudios de valoración inmobiliaria, el tamaño del espacio habitable es el principal determinante del valor de una vivienda, ya que representa el área realmente utilizable por el comprador.

2. **OverallQual (Calidad general de la vivienda)**

La calidad de los materiales y el acabado de la construcción influye directamente en el valor percibido y en el costo total de la propiedad. La literatura en tasación muestra que una mayor calidad incrementa significativamente el precio.

3. **GarageCars (Capacidad del garaje)**

El espacio disponible para estacionamiento es un atributo valorado especialmente en zonas suburbanas como Ames. Estudios muestran que la disponibilidad de garaje aumenta la utilidad, la seguridad y el valor de la vivienda.

4. **GarageArea (Área del garaje)**

Además del número de autos, el tamaño total del garaje incrementa el valor de la propiedad, ya que agrega espacio funcional para almacenamiento y mejora de vehículos.

5. **TotalBsmtSF (Área total del sótano)**

El sótano aporta área adicional a la vivienda. Las propiedades con mayor superficie subterránea suelen tener un valor mayor, pues el espacio puede destinarse a bodegas, habitaciones o áreas recreativas.

6. **1stFlrSF (Área del primer piso)**

El área del primer piso suele ser la más grande y funcional dentro de la vivienda. Es un fuerte predictor del valor total debido a que está directamente relacionado con la distribución principal del hogar.

7. **BsmtFinSF1 (Área terminada del sótano)**

Un sótano terminado incrementa significativamente el valor porque añade espacio habitable adicional. La literatura inmobiliaria confirma que los espacios terminados elevan el precio por metro cuadrado.

8. FullBath (Baños completos)

El número de baños completos es un factor clave en tasación. Más baños aumentan la funcionalidad y el confort del inmueble, lo que se traduce en un mayor precio de mercado.

9. LotArea (Tamaño total del terreno)

El tamaño del terreno está directamente relacionado con la valoración del suelo. Terrenos más amplios incrementan el valor base de la propiedad, especialmente en mercados suburbanos.

10. YearBuilt (Año de construcción)

El año en que fue construida la vivienda permite medir la antigüedad y depreciación. En economía inmobiliaria, construcciones más modernas suelen tener mayor valor debido a mejores normativas, materiales y eficiencia.

Además de otras investigaciones, se utilizaron principalmente dos artículos base ampliamente reconocidos. Sirmans, Macpherson y Zietz (2005) analizan más de 150 estudios y resaltan variables como área habitable, tamaño del lote, calidad, baños, garaje y sótanos. Por su parte, Malpezzi (2002) revisa los modelos hedónicos y destaca la importancia del área construida, la calidad y la antigüedad de la vivienda.

RESOLUCIÓN

FASES PROPUESTAS EN EL PRIMER BIMESTRE

Desde la planificación inicial del proyecto presentados en el primer bimestre se propusieron las siguientes etapas de trabajo:

1. Se planteó una preparación inicial del dataset utilizando el archivo train.csv con el objetivo de alcanzar una matriz de datos coherente con el modelo matemático planteado en esta etapa se efectuó la separación de la variable objetivo (salePrice) y las variables explicativas eliminando así atributos no relevantes para esta etapa de análisis además se verificó que las variables utilizadas fueran numéricas permitiendo la aplicación de operaciones algebraicas necesarias para el método de mínimos cuadrados y finalmente se usaron técnicas de pre procesamiento según el modelo evaluado incluyendo normalización de variable y limpieza mediante análisis de valores atípicos con el propósito de mejorar la estabilidad y validez de la solución del sistema
2. El modelo lineal multivariable puede escribirse en forma matricial

$$(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) \quad (4)$$

Se construyó la matriz X con las 10 variables explicativas además se añadió una columna de unos para representar el término independiente

3. Se organizo las variables en forma matricial para aplicar el modelo lineal multi-variable y definir el sistema de ecuaciones correspondiente al metodo de mínimos cuadrados

DESCRIBIR LA ETAPA DEL ANÁLISI (INCLUYE FASE DE LIMPIEZA DE DATOS)

Antes de aplicar el modelo matematico se desarrollo una fase de analisis numérico que permitio preparar adecuadamente la informacion del dataset:

1. **Selección y revisión de datos** se trabajo unicamente con variables seleccionadas del archivo train.csv usando las variables mas importante mismas que son fundamentales para usarles en el modelo lineal multivariable en esta etapa se observa la consistencia del dataset confirmando que las variables elegidas mostradas no presentan valores faltantes ni inconsistencias que afecten la aplicacion del metodo de mínimos cuadrados
2. **Análisis descriptivo** Se analizaron parametros estadisticos necesarios para el procesamiento adecuado del modelo se usaron medias y desviacion estandar utilizando mas adelante en el proceso de normalizacion ademas la variabilidad significa en algunas variables relacionada con características estructurales de las viviendas lo cual sugiere una influencia significativa en el precio final de la vivienda
3. **Preparación para el modelo** Las variables fueron organizadas de manera matricial para la implementación del modelo lineal multivariable determinando así el sistema de ecuaciones correspondiente al metodo de mínimos cuadrados ademas en etapas posteriores se aplicaron tecnicas de normalizacion y analisis mediante diagramas de caja para evaluar el impacto de valores atipicos en el ajuste del modelo

MÉTODOS NUMÉRICOS UTILIZADOS DENTRO DEL PROYECTO

El metodo numerico utilizado es el de minimos cuadrados ya que al construir un modelo lineal, en la mayoría de los casos no se va a ajustar exactamente a todos los datos reales por lo que se hace uso de una función de error que mide que tan alejadas o cercanas están las predicciones del modelo respecto a los valores reales.

Esta función de error es la suma de los errores al cuadrado que permite penalizar los errores grandes, minimizar esta función significa encontrar los coeficientes que hacen que el modelo se acerque lo mas posible a los datos reales.

Para encontrar estos coeficientes se lo hace igual que como lo vimos en clase se deriva la función de error respecto a cada coeficiente y se igualan las derivadas a cero

$$E = \sum_{i=1}^n [y_i - (a_1 x_i + a_0)]^2 \quad \Rightarrow \quad \min \sum_{i=1}^n [y_i - f(x_i)]^2 \quad (5)$$

FUNCIONES IMPLEMENTADAS

1. Carga y preparación de datos

Funciones:

- def cargar_dataset(ruta_archivo): carga el dataset desde un archivo CSV.
- def cargar_datos(ruta_archivo): carga el dataset para otros modelos.
- def separar_variables(df, columna_objetivo): separa variables independientes X y dependiente y.
- def preparar_datos(X, y, columna_id): elimina columnas no importantes y convierte los datos a forma matricial.
- def separar_y_normalizar(df, columna_objetivo="SalePrice", columna_id="Id"): separa y normaliza los datos.

Estructuras de datos utilizadas:

- DataFrame: organiza datos en filas y columnas
- Matrices NumPy: arreglos bidimensionales para realizar operaciones
- Vectores NumPy: arreglos unidimensionales para el calculo de datos numéricos.

2. Construcción del modelo matricial

Funciones: def construir_matriz_modelo(X_norm): construye la matriz del modelo a partir de datos normalizados. **Estructuras de datos utilizadas:** Matrices NumPy: arreglos bidimensionales para realizar operaciones

3. Método de mínimos cuadrados

Funciones: def calcular_minimos_cuadrados(matriz_A, vector_b): calcula los coeficientes del modelo mediante ecuaciones . **Estructuras de datos utilizadas:**

- Matriz NumPy
- Vector NumPy

4. Predicción

Funciones:

- def predecir_precios(matriz_A, coeficientes): calcula los valores estimados del modelo base.
- def predecir (A, coeficientes): realiza predicciones con datos normalizados.
- def predecir_test_modelo_3(X_test_norm_m3, y_test_m3, coeficientes_train_m3): predice sobre el conjunto de prueba del modelo 3.

Estructuras de datos utilizadas:

- Matrices NumPy
- Vectores NumPy

5. Evaluación del modelo

Funciones:

- `def calcular_rmse(y, precios_estimados)`: calcula el RMSE del modelo base.
- `def calcular_rmse_normalizado(y, y_pred_norm)`: calcula el RMSE del modelo normalizado.
- `def generar_tabla_errores(df, y, precios_estimados)`: genera una tabla con errores absolutos.
- `def obtener_top_mejores_predicciones(df, y, precios_estimados, top_n=10)`: obtiene las mejores predicciones.
- `def obtener_top_peores_predicciones(df, y, precios_estimados, top_n=10)`: obtiene las peores predicciones.
- `def evaluar_vivienda_por_id(df, y, precios_estimados)`: evalúa una vivienda específica.

Estructuras de datos utilizadas:

- DataFrame
- Vectores NumPy

6. Visualización de resultados

Funciones:

- `def graficar_predicciones(y_real, y_estimado)`: grafica valores reales vs estimados.
- `def graficar_comparacion_por_id(id_vivienda, precio_real, precio_estimado)`: compara precios por vivienda.
- `def analizar_influencia_variables(X, coeficientes_modelo, columna_id=Íd)`: analiza influencia de variables.
- `def graficar_influencia_variables(tabla_influencia)`: grafica la influencia de las variables.
- `def graficar_top_mejores_predicciones(top_mejores)`: grafica mejores predicciones.
- `def graficar_top_peores_predicciones(top_peores)`: grafica peores predicciones.
- `def graficar_rmse(RMSE)`: grafica el RMSE.
- `def graficar_error_absoluto_por_vivienda(tabla_errores)`: grafica el error absoluto.

Estructuras de datos utilizadas:

- DataFrame
- Vectores NumPy
- Valores escalares: representan un único dato numérico sin dimensiones

7. Modelo 3 (outliers y train-test)

Funciones:

- `def limpiar_outliers_boxplot(df, columna_objetivo="SalePrice")`: elimina valores atípicos.
- `def dividir_train_test_modelo_3(df_m3, test_size=0.3, random_seed=42)`: divide datos en entrenamiento y prueba.
- `def entrenar_modelo_3(df_m3, columna_objetivo="SalePrice", columna_id="Id")`: entrena el modelo 3.
- `def entrenar_modelo_3_con_train(X_train_norm_m3, y_train_m3)`: entrena usando solo el conjunto de entrenamiento.

Estructuras de datos utilizadas:

- DataFrame
- Matrices NumPy
- Vectores NumPy

FLUJOGRAMA DE INTERACCIONES ENTRE FUNCIONES IMPLEMENTADAS

Según IBM, un diagrama de flujo es una representación visual de las etapas de un proceso o algoritmo, que muestra la secuencia de pasos de forma clara y estructurada para facilitar la comprensión y la toma de decisiones.




Figura: Flujograma

LINK DEL REPOSITORIO

Repositorio de GitHub: Repositorio metodos_2025B_house_prices

ESTADÍSTICAS DE CONTRIBUCIONES DEL REPOSITORIO




Figura: Commits

CONCLUSIONES

- El uso del diagrama de cajas permite identificar valores extremos que podan distorsionar el ajuste del modelo. La eliminación de estos registros en el Modelo 3 contribuyó a mejorar la capacidad predictiva general evidenciando la importancia del análisis exploratorio previo en modelos basados en mínimos cuadrados.
- La normalización de datos permitió reducir problemas derivados de las diferencias de escala entre variables y así mejora la estabilidad numérica del modelo. Aunque el modelo sin normalizar logró resultados aceptables la versión normalizada mostró un comportamiento más consistente en el cálculo de coeficientes y en la interpretación de la influencia de las variables.
- El método de mínimos cuadrados busca minimizar la suma de los cuadrados de los residuos, pero no elimina totalmente el error entre los datos reales y la aproximación del modelo. El desarrollo teórico clásico en análisis numérico establece que la diferencia entre la función real y la aproximación con mínimos cuadrados representa un error de aproximación inevitable, que depende de cómo los datos se ajustan a la forma del modelo elegido. [4]
- Se observaron casos con errores elevados lo cual es esperable en modelos lineales aplicados a datos reales debido a factores no considerados dentro del conjunto de variables y posibles relaciones no lineales presentes en el mercado inmobiliario. A pesar de ello, el modelo logra minimizar el error global, cumpliendo el objetivo principal del método de mínimos cuadrados.

RECOMENDACIONES

- Se recomienda considerar la inclusión de variables adicionales que puedan influir en el precio de la vivienda, como características relacionadas con la ubicación específica, condiciones del entorno o variables temporales del mercado la incorporación de más información podría reducir los errores observados en ciertas predicciones y mejorar la capacidad explicativa del modelo
- El uso del diagrama de cajas demostró ser útil para identificar valores atípicos; sin embargo se recomienda complementar este análisis con otras técnicas o criterios de negocio antes de eliminar registros para evitar perder información potencialmente relevante
- Se recomienda mantener el enfoque interpretativo del modelo hedónico ya que permite comprender cómo cada característica contribuye al precio final lo cual resulta útil para análisis económicos y toma de decisiones

REFERENCIAS

- [1] J. Chica Olmo, R. Cano Guervos, and M. Chica Olmo, “Modelo hedónico espacio-temporal y análisis variográfico del precio de la vivienda,” *GeoFocus*, vol. 7, pp. 56–72, 2007.
- [2] J. F. Castaño Lavado and M. Morales Mosquera, “Revisión metodológica de índices de precios de la vivienda,” Banco de la República de Colombia, Tech. Rep. 81, julio 2015.
- [3] J. Abad Sánchez, “Precios de la vivienda: sobrevaloración y burbuja,” Trabajo de Fin de Grado, Universidad Complutense de Madrid, junio 2013.
- [4] Escuela Politécnica Nacional, “Métodos numéricos,” <https://bibdigital.epn.edu.ec/bitstream/15000/10022/4/MetodosNumericos.pdf>, s.f., material académico, Biblioteca Digital EPN.
- [5] S. Rosen, “Hedonic prices and implicit markets: Product differentiation in pure competition,” *Journal of Political Economy*, vol. 82, no. 1, pp. 34–55, 1974.
- [6] C. Bilbao Terol, “Relación entre el precio de venta de una vivienda y sus características: un análisis empírico para asturias,” *Revista Asturiana de Economía*, vol. 18, pp. 141–169, 2000.
- [7] C. I. Kim, “Explaining housing prices: From the perspective of the interaction between age and floor area ratio,” *Journal of Real Estate Analysis*, vol. 4, no. 1, pp. 1–14, 2018.
- [8] D. Albalade *et al.*, “The determinants of garage prices and their interaction with housing prices,” *Journal of Real Estate Economics (o nombre real de la revista)*, vol. número volumen de la revista — si lo sabes, no. número del fascículo — si lo sabes, p. 5, 2017.
- [9] G. S. Sirmans, D. A. Macpherson, and E. N. Zietz, “The composition of hedonic pricing models,” *Journal of Real Estate Literature*, vol. 13, no. 1, p. 3–43, 2005, jSTOR stable link 44103506.
- [10] D. Albalade and A. Gragera Lladó, “The determinants of garage prices and their interaction with curbside regulation,” *Transportation Research Part A: Policy and Practice*, vol. 101, pp. 86–97, 2017.
- [11] N. Apellido and N. Apellido2, “Título del artículo,” *Nombre de la revista*, vol. xx, no. yy, pp. pp–qq, 2025.

- [12] D. De Cock, “Ames, iowa: Alternative to the boston housing data as an end of semester regression project,” *Journal of Statistics Education*, vol. 19, no. 3, pp. 1–17, 2011, disponible en jse.amstat.org/v19n3/decock.pdf.
- [13] S. Malpezzi, “Hedonic pricing models: A selective and applied review,” *Housing Economics: Essays in Honor of Duncan MacLennan*, 2002, prepared for: The Center for Urban Land Economics Research, University of Wisconsin; 45 págs.
- [14] G. S. Sirmans, D. A. Macpherson, and E. N. Zietz, “The composition of hedonic pricing models,” *Journal of Real Estate Literature*, vol. 13, no. 1, pp. 1–44, 2005.
- [15] A. C. Goodman, “Dwelling-age-related heteroskedasticity in hedonic house price equations,” *Journal of Real Estate Finance and Economics*, vol. 15, no. 1, pp. 43–55, 1997, jSTOR stable link 24833644.